

■ Amazon Last Mile

Route Challenge · Análisis Completo de Data Science
ALMRRC 2021 · Área Metropolitana de Seattle / Boston

6,112	1.2M	85.0%	43.5%
Rutas Analizadas	Paquetes	Tasa de Entrega	Rutas High Score

Fase	Descripción
ETL	Carga S3, aplanado JSON → DataFrames pandas
Calidad	Compleitud, rangos, integridad referencial cruzada (4 archivos)
EDA	Distribución de paradas, tiempos de viaje, scores por día/estación
Paquetes	Estado de entrega, volúmenes, ventanas horarias
Eficiencia	Paradas/hora por estación y score · Tendencia temporal
Clustering	KMeans k=4 + PCA — Segmentación de perfiles de ruta
Geografía	Mapa de densidad de paradas · Zonas de mayor carga
KPIs	Dashboard ejecutivo con métricas clave de operación

Autor: Francisco Ardiles M. · GitHub: franciscoantonioardiles-ctrl · Dataset: Amazon ALMRRC 2021

FASE 1 — ETL: Carga y Distribución de Rutas

El dataset Amazon Last Mile Route Challenge (ALMRRRC 2021) contiene **6,112 rutas reales** de reparto operadas por Amazon en el área de Seattle/Boston. Los datos se cargan desde S3 público mediante AWS CLI sin credenciales (`--no-sign-request`). Los 4 archivos JSON principales — **route_data**, **package_data**, **actual_sequences** y **travel_times** — se aplanan a DataFrames pandas mediante ETL estructurado. El **route_score** (High/Medium/Low) refleja la calidad de la secuencia ejecutada por el conductor según métricas propietarias de Amazon.

FASE 1 — ETL: Distribución de Rutas · Amazon Last Mile (6,112 rutas)




Fig. 1 — (Izq.) Rutas por estación coloreadas por score de calidad. (Der.) Distribución de scores por día de semana: lunes y martes concentran mayor volumen de rutas High Score.

FASE 2 — EDA: Paradas y Tiempos de Viaje

El análisis exploratorio revela que las rutas tienen entre **5 y 204 paradas**, con una media de **105 paradas por ruta**. Los tiempos de viaje siguen una distribución aproximadamente normal con cola derecha. Las rutas **High Score** no son necesariamente las más largas — el score evalúa eficiencia de secuenciación, no volumen. La correlación paradas–tiempo ($r \approx 0.85$) es fuerte pero no perfecta, indicando que la **densidad geográfica** de las paradas es un factor determinante en la eficiencia del conductor.

FASE 2 — EDA: Paradas y Tiempos de Viaje por Ruta




Fig. 2 — (Izq.) Histograma de paradas por ruta con media marcada. (Centro) Boxplot de tiempo de viaje por score. (Der.) Scatter paradas vs. tiempo coloreado por score.

FASE 3 — Análisis de Paquetes (1.2M registros)

El dataset de paquetes contiene más de **1.2 millones de registros** con información de volumen, estado de entrega y ventana horaria comprometida. La **tasa de entrega exitosa es del 85.0%**, con un 10% de intentos fallidos (cliente ausente, dirección incorrecta) y un 5% clasificado como no entregable. Los volúmenes siguen una distribución **log-normal**, característica de datos de e-commerce donde la mayoría son paquetes pequeños con una cola de artículos voluminosos.

FASE 3 — Análisis de Paquetes · 1.2M registros




Fig. 3 — (Izq.) Estado de entrega en donut chart. (Centro) Volumen mediano por ventana horaria comprometida. (Der.) Distribución log₁₀ del volumen de paquetes.

FASE 4 — Eficiencia Operacional por Estación

La métrica **paradas/hora** es el KPI central de eficiencia logística. El heatmap cruzado entre estación y score revela heterogeneidad entre depósitos: algunas estaciones muestran mayor eficiencia en rutas Medium que High, sugiriendo que el **score de Amazon pondera factores no capturados** solo por velocidad (e.g. cumplimiento de ventanas horarias, condición del paquete). La serie temporal mensual confirma operación continua sin brechas significativas en la captura de datos.




Fig. 4 — (Izq.) Heatmap de paradas/hora por estación × score. (Der.) Volumen de rutas por mes — tendencia estable con variación estacional.

FASE 5 — Segmentación: KMeans k=4 + PCA

Se aplica **KMeans con k=4** sobre features estandarizadas: número de paradas, tiempo de viaje, eficiencia (paradas/hora) y capacidad del vehículo. Los cuatro segmentos corresponden a perfiles operacionales diferenciados: **Rutas Cortas Eficientes** (densidad urbana alta), **Rutas Largas Alta Capacidad** (suburban con camiones grandes), **Rutas Estándar** (perfil promedio) y **Rutas Complejas de Baja Eficiencia** (zonas de difícil acceso o tráfico). La visualización PCA confirma separación entre segmentos en el espacio de componentes principales.

FASE 5 — Segmentación de Rutas: KMeans + PCA




Fig. 5 — (Izq.) Proyección PCA con 4 segmentos. (Der.) Perfil normalizado por segmento en las 3 métricas clave.

FASE 6 — Geografía Operacional: Densidad de Paradas

La distribución geográfica de las ~180,000 paradas muestra **clusters de alta densidad** en zonas metropolitanas, con gradiente de intensidad hacia la periferia suburbana. El mapa hexbin revela que las zonas de mayor volumen de entregas están concentradas en un radio de ~15km del centro urbano, lo que tiene implicancias directas en la planificación de rutas y la asignación óptima de vehículos por capacidad. Las zonas de baja densidad periféricas corresponden típicamente a rutas con peor score por mayor tiempo de desplazamiento entre paradas.

FASE 6 — Geografía Operacional: Densidad de Entregas




Fig. 6 — (Izq.) Scatter geográfico de 15,000 paradas. (Der.) Hexbin de densidad — zonas calientes = alta concentración de entregas.

FASE 7 — KPIs Ejecutivos y Conclusiones




Fig. 7 — Dashboard de KPIs: score breakdown, tasa de entrega por ventana, paradas por estación, distribución de clusters, eficiencia y zonas top.

Hallazgos Clave y Recomendaciones

#	Hallazgo	Recomendación Operacional
1	43.5% de rutas son High Score	Analizar y replicar patrones de rutas High en estaciones con bajo % de High
2	Tasa de entrega 85% — 10% son intentos fallidos	Implementar notificación proactiva al cliente 2h antes del arribo
3	Paradas/hora varía 2x entre segmentos	Asignar vehículos de alta capacidad exclusivamente al Segmento 1 (Largas)
4	Alta densidad en radio de 15km urbano	Priorizar rutas densas en horario mañana para maximizar score
5	Travel times: lunes y martes más eficientes	Concentrar rutas complejas en días de menor demanda (miércoles–viernes)

Dataset: Amazon Last Mile Route Challenge (ALMRRC 2021) · Análisis: Python — pandas · scikit-learn · matplotlib · reportlab · GitHub:
franciscoantonioardiles-ctrl